

از زمان معرفی مقاله "Attention Is All You Need" در سال ۲۰۱۷، معماری ترانسفورمر (Transformer) به استاندارد طلایی در پردازش زبان طبیعی (NLP) تبدیل شده است. با این حال، استفاده از این معماری در داده‌های سری زمانی (Time Series) تا مدت‌ها با چالش‌های جدی روبه‌رو بود. داده‌های سری زمانی برخلاف کلمات در یک جمله، دارای پیوستگی عددی، نویز بالا و وابستگی‌های زمانی بسیار پیچیده‌تری در فواصل طولانی هستند. در سال‌های اخیر، محققان معماری‌های متعددی را برای سازگار کردن ترانسفورمرها با این نوع داده‌ها توسعه داده‌اند.

چالش‌های مکانیزم توجه (Self-Attention) در سری‌های زمانی

مکانیزم توجه استاندارد دارای پیچیدگی زمانی و حافظه $O(L^2)$ است (که در آن L طول توالی یا Sequence Length است). در پیش‌بینی‌های طولانی‌مدت (Long-term Forecasting)، ما نیاز داریم که به صدها یا هزاران نقطه زمانی گذشته نگاه کنیم. این پیچیدگی محاسباتی باعث می‌شود اجرای ترانسفورمرهای استاندارد روی داده‌های فرکانس بالا (مثل داده‌های لحظه‌ای بورس یا سنسورهای اینترنت اشیا) عملاً غیرممکن شود. علاوه بر این، مکانیزم توجه به صورت ذاتی نسبت به ترتیب داده‌ها بی‌تفاوت (Permutation Invariant) است، در حالی که در سری‌های زمانی، تقدم و تأخر داده‌ها کلیدی‌ترین عنصر پیش‌بینی است.

تکامل رمزگذاری موقعیتی (Positional Encoding)

برای حل مشکل بی‌تفاوتی به ترتیب، روش‌های مختلفی برای رمزگذاری موقعیتی پیشنهاد شد. روش‌های اولیه از توابع سینوسی و کسینوسی ثابت استفاده می‌کردند. اما به زودی مشخص شد که این توابع برای درک وابستگی‌های نسبی (Relative) در سری‌های زمانی کافی نیستند. تکنیک‌هایی مانند RoPE (Rotary Position Embedding) با اعمال چرخش روی بردارهای توجه، توانستند اطلاعات نسبی را بهتر حفظ کنند. در حوزه‌های مالی، روش tAPE (Temporal Absolute Positional Encoding) معرفی شد که به طور خاص نوسانات فصلی و روندهای کلان را در برمی‌گرفت و باعث کاهش خطای مدل (MSE) در پیش‌بینی قیمت سهام گردید.

معماری‌های نوین: Informer و Autoformer

برای غلبه بر مشکل پیچیدگی محاسباتی $O(L^2)$ ، شبکه‌ای به نام Informer با ایده ProbSparse Attention معرفی شد که پیچیدگی را به $O(L \log L)$ کاهش داد. این مدل با انتخاب توزیع‌های احتمالی گلی، تنها به مهم‌ترین نقاط زمانی توجه می‌کند. در ادامه، معماری Autoformer با الهام از روش‌های کلاسیک تحلیل سری‌های زمانی (مانند تجزیه روند و فصل‌گرایی یا Decomposition) پا به عرصه گذاشت. Autoformer به جای توجه متقاطع استاندارد، از مکانیزم Auto-Correlation استفاده می‌کند که شباهت‌های دوره‌ای (Periodicity) را مستقیماً از خود سیگنال استخراج می‌کند و در پیش‌بینی داده‌های آب‌وهوایی و مصرف انرژی عملکرد خیرمکننده‌ای ثبت کرده است.

نتیجه‌گیری

استفاده از ترانسفورمرها در پیش‌بینی سری‌های زمانی دیگر یک ایده خام نیست، بلکه با ظهور معماری‌هایی که همزمان مشکل پیچیدگی حافظه و درک ساختار زمانی را حل کرده‌اند، به یک ابزار قدرتمند تبدیل شده است. انتظار می‌رود در آینده، ترکیب این شبکه‌ها با مدل‌های چندوجهی (Multi-modal) بتواند داده‌های متنی (مثل اخبار) را نیز در کنار داده‌های عددی برای پیش‌بینی‌های دقیق‌تر ادغام کند.